



METTRE EN PLACE UN PIPELINE D'ORCHESTRATION DES FLUX

Pipeline mensuel automatisé avec Kestra

Projet Data Engineer – **KELLEN** Antoine

[lien GitHub](#) 1



ROADMAP DE LA MISSION

1. **Contexte & objectifs**
2. Données sources (Input Files)
3. Architecture d'automatisation/data lineage
4. Différentes étapes du Workflow
5. Conclusion

Contexte & objectifs

Contexte :

- Bottleneck : marchand de vins avec données dispersées (ERP, site e-commerce, liaison).
- Fragmentation = doublons, incohérences, difficultés de rapprochement.
- Les équipes manquent d'une vision mensuelle fiable des ventes.
- Les traitements actuels sont manuels et sources d'erreurs.

Objectif :

1. Automatiser le traitement mensuel via un pipeline Kestra.
2. Nettoyer, dédoublonner et harmoniser les trois sources.
3. Reconstituer une correspondance produit fiable ERP ↔ Web.
4. Calculer le chiffre d'affaires par produit et total.
5. Identifier les vins premium (méthode z-score).
6. Générer des exports clairs et exploitables par le métier.

ROADMAP DE LA MISSION

1. Contexte & objectifs
2. **Données sources (Input Files)**
3. Architecture d'automatisation/data lineage
4. Différentes étapes du Workflow
5. Conclusion

Données sources (Input Files)

Les 3 fichiers d'entrée utilisés :

- ERP : product_id, prix, stock
- Web : sku, titre produit, ventes totales
- Liaison : product_id ↔ id_web

erp : (825, 5)

web : (1513, 28)

liaison : (825, 2)

ERP

' ERP : '

	product_id	onsale_web	price	stock_quantity	stock_status
0	3847	1	24.2	0	outofstock
1	3849	1	34.3	0	outofstock
2	3850	1	20.8	0	outofstock
3	4032	1	14.1	0	outofstock
4	4039	1	46.0	0	outofstock

WEB

' WEB : '

	sku	virtual	downloadable	rating_count	average_rating	total_sales	tax_status	tax_class	post_author	post_date	...	post_name	post_modified	post_modified_gmt	post_content_filtered	post_parent	guid	n
0	16004	0	0	0	0.0	5.0	NaN	NaN	2.0	2018-06-07 16:27:25	...	chateau-du-couvent-pomerol-2017	2020-08-25 18:35:02	2020-08-25 16:35:02	NaN	0.0	https://www.bottle-neck.fr/wp-content/uploads/...	n
1	NaN	0	0	0	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	
2	15075	0	0	0	0.0	3.0	taxable	NaN	2.0	2018-02-14 15:39:43	...	pares-balta-penedes-indigena-2017	2020-08-20 15:35:02	2020-08-20 13:35:02	NaN	0.0	https://www.bottle-neck.fr/?post_type=product&...	
3	16209	0	0	0	0.0	6.0	taxable	NaN	2.0	2018-02-14 17:15:31	...	maurel-cabardes-tradition-2017	2020-08-05 18:05:03	2020-08-05 16:05:03	NaN	0.0	https://www.bottle-neck.fr/?post_type=product&...	
4	15763	0	0	0	0.0	1.0	NaN	NaN	2.0	2020-01-25 14:08:16	...	domaine-de-la-monardiere-vacqueyras-les-vieill...	2020-08-21 11:35:02	2020-08-21 09:35:02	NaN	0.0	https://www.bottle-neck.fr/wp-content/uploads/...	

5 rows x 28 columns

LIAISON

' LIAISON : '


	product_id	id_web
0	3847	15298
1	3849	15296
2	3850	15300
3	4032	19814
4	4039	19815

ROADMAP DE LA MISSION

1. Contexte & objectifs
2. Données sources (Input Files)
3. **Architecture d'automatisation/data lineage**
4. Différentes étapes du Workflow
5. Conclusion

Architecture d'automatisation & data lineage

Organisation du pipeline et circulation des données



Ce diagramme illustre le pipeline complet :

Le workflow charge, nettoie et fusionne les trois sources (ERP, Web, Liaison).

Il calcule le CA, identifie les vins premium, génère les exports métier et s'exécute automatiquement chaque mois.

ROADMAP DE LA MISSION

1. Contexte & objectifs
2. Données sources (Input Files)
3. Architecture d'automatisation/data lineage
4. **Différentes étapes du Workflow**
5. Conclusion

Workflow vue d'ensemble

Étape 1 : Excel → CSV


Étape 2 : Chargement DuckDB

Étape 3 : Nettoyage et dédoublonnage

Étape 4 : Jointure multi-systèmes

Étape 5 : Calcul du CA

Étape 6-7 : Export CA + détection premium




Vue topologie Kestra




Nettoyage / dédoublonnage

Garantir 1 ligne = 1 produit (vin) pour chaque source.


- ERP : 1 ligne par product_id (825)
- Web : 1 ligne par sku (714)
- Liaison : 1 ligne par product_id (825)
- Technique : ROW_NUMBER() + rn = 1
- Tests automatiques sur les tailles attendues



```
# 3bis) TESTS : tailles attendues après nettoyage (825 / 714 / 825)
- id: test_clean_counts
  type: io.kestra.plugin.jdbc.duckdb.Query
  url: jdbc:duckdb:/tmp/kestra-wd/bottleneck.db
  fetchType: FETCH
  sql: |
    SELECT CASE
      WHEN (SELECT COUNT(*) FROM erp_clean) = 825
      AND (SELECT COUNT(*) FROM web_clean) = 714
      AND (SELECT COUNT(*) FROM liaison_clean) = 825
      THEN 1
      ELSE 0
    END AS test_clean_counts;
```




Tasks			Outputs	
convert_erp	4 items	>	row	
convert_web	4 items	>	rows	{ "test_clean_counts": 1
convert_liaison	4 items	>	size	1
load_duckdb	4 items	>	outputFiles	outputFiles
clean_tables	4 items	>		
test_clean_counts	4 item	>		



Jointure

Fusion des 3 sources pour avoir une vision produit complète

1. Jointure ERP_clean ↔ Liaison_clean (product_id)
2. Jointure Liaison_clean ↔ Web_clean (id_web = sku)
3. Cast BIGINT pour fiabiliser les clés
4. Résultat final : 714 vins propres
5. Test : aucune valeur nulle dans les colonnes clés



Calcul du C.A.

CA par produit

Après la jointure, on a 1 ligne par vin (714 vins) avec :

- price (prix ERP)
- total_sales (ventes Web)

On calcule alors le CA de chaque vin : $\text{chiffre_affaires} = \text{price} * \text{total_sales}$

Donc chaque ligne devient :


- 1 vin
- son CA

CA total

Ensuite, on additionne tous les CA par vin pour obtenir le CA global :

```
SELECT SUM(chiffre_affaires) FROM ca;
```


Résultat = 65 652,60 €



Détection des vins premium

Approche statistique pour repérer les prix atypiques

- 1.Calcul z-score sur les prix ERP
- 2.Premium si $z > 2$
- 3.30 vins premium / 684 ordinaires
- 4.Export dans deux CSV propres



```
data_bottleneck > output_final > vins_premium.csv > data
1 product_id,product_name,price,total_sales,chiffre_affaires,zscore,premium
2 4115,Zind-Humbrecht Riesling Grand Cru Rangen De Thann Clos Saint-Urbain 2017,100.0,0.0,0.0,2.427385420938595,True
3 4132,Zind-Humbrecht Pinot Gris Grand Cru Rangen De Thann Clos Saint-Urbain 2012,88.4,0.0,0.0,2.0102771487143416,True
4 4352,Champagne Egly-Ouriet Grand Cru Millésimé 2008,225.0,5.0,1125.0,6.922086630251679,True
5 4355,Champagne Egly-Ouriet Grand Cru Blanc de Noirs,126.5,11.0,1391.5,3.380262077312969,True
```

Vins premium

```
data_bottleneck > output_final > vins_ordinaires.csv > data
1 product_id,product_name,price,total_sales,chiffre_affaires,zscore,premium
2 3847,Pierre Jean Villa Saint-Joseph Préface 2018,24.2,6.0,145.2,-0.2982013923888578,False
3 3849,Pierre Jean Villa Saint-Joseph Rouge Tildé 2017,34.3,0.0,0.0,0.06497046532363923,False
4 3850,Pierre Jean Villa Crozes-Hermitage Accroche Coeur 2018,20.8,0.0,0.0,-0.4204572652821736,False
5 4032,Pierre Jean Villa IGP Collines Rhodaniennes Gamine 2018,14.1,3.0,42.3,-0.6613732501013548,False
```

Vins ordinaire


Rapport du C.A.

Ce que l'entreprise reçoit à chaque exécution.

- Le rapport contient 2 onglets :
- Détail_CA : une ligne par vin (714 lignes), avec prix, ventes et CA.
 - Résumé : indicateurs clés → nombre total de vins et CA consolidé.

Le fichier est produit à chaque exécution mensuelle.

Format livrable : rapport_chiffre_affaires.xlsx



data_bottleneck > output_final > rapport_chiffre_affaires.xlsx

	A	B
1	indicateur	valeur
2	Nombre de lignes	714
3	Chiffre d'affaires total (€)	65,652.60

Navigation: ⏮ ⏪ ⏩ ⏭

Onglets: Détail_CA | **Résumé**

data_bottleneck > output_final > rapport_chiffre_affaires.xlsx


	A	B	C	D	E
1	product_id	product_name	price	total_sales	chiffre_affaires
2	3,847	Pierre Jean Villa	24.20	6	145.20
3	3,849	Pierre Jean Villa	34.30	0	0
4	3,850	Pierre Jean Villa	20.80	0	0
5	4,032	Pierre Jean Villa	14.10	3	42.30
6	4,039	Pierre Jean Villa	46	0	0
7	4,040	Pierre Jean Villa	34.30	0	0
8	4,041	Pierre Gaillard C	32.70	0	0
9	4,042	Pierre Gaillard C	31.20	7	218.40
10	4,043	Pierre Gaillard C	60	3	180
11	4,045	Pierre Gaillard C	42.60	14	596.40
12	4,046	Pierre Gaillard C	80	6	480
13	4,047	Pierre Gaillard C	18.30	0	0
14	4,048	Pierre Gaillard S	22.80	7	159.60
15	4,049	Pierre Gaillard S	19.30	1	19.30
16	4,050	Pierre Gaillard S	21.80	6	130.80
17	4,051	Jeanne Gaillard I	7.70	6	46.20
18	4,052	Clos du Mont-O	33.70	6	202.20
19	4,053	Clos du Mont-O	44.30	23	1,018.90
20	4,054	Clos du Mont-O	71.60	10	716
21	4,056	Clos du Mont-O	12.70	10	127
22	4,057	Mourgues du Gr	8.70	18	156.60
23	4,058	Mourgues du Gr	8.70	11	95.70
24	4,059	Mourgues du Gr	8.70	7	60.90
25	4,060	Mourgues du Gr	11.90	9	107.10
26	4,062	Mourgues du Gr	11.90	3	35.70
27	4,063	Mourgues du Gr	14.50	3	43.50
28	4,064	Oratoire Saint M	14.40	3	43.20
29	4,065	Oratoire Saint M	19.50	0	0
30	4,066	Oratoire Saint M	20.80	20	416
31	4,067	Gilles Robin Cro	22	19	418

Navigation: ⏮ ⏪ ⏩ ⏭

Onglets: **Détail_CA** | Résumé

CRON — Exécution mensuelle

Ce que l'entreprise reçoit à chaque exécution.



Automatisation complète via une tâche CRON.

Déclenchement : 15 du mois • 09:00

Pas de manipulation manuelle → fiabilité accrue.

Pipeline livré au métier tous les mois.

```
triggers:
- id: monthly15-09h
  type: io.kestra.plugin.core.trigger.Schedule
  cron: "0 9 15 * *"
```

kestra.

Dashboards

Flows

Apps

Executions

Logs

Tests

Flows

Add filters

Search flows

Scope equals USER

Id	Labels	Namespace	Last execution date	Last execution status	Execution statistics	Triggers	Actions
ai-agent-calling-flows		tutorial					
ai-check-weather-gemini		company.team	Mon, Nov 24, 2025				
bottleneck_pipeline_ETL		bottleneck	Thu, Nov 20, 2025				
bottleneck_workflow		bottleneck	Fri, Nov 21, 2025 6				

Trigger details: monthly15-09h

Name	Value
Id	monthly15-09h
Type	io.kestra.plugin.core.trigger.Schedule
Cron	At 09:00 AM, on day 15 of the month

Livrables

Ce que l'entreprise reçoit à chaque exécution.

- Fichiers :
 - rapport_chiffre_affaires.xlsx
 - vins_premium.csv
 - vins_ordinaires.csv

```
data_bottleneck > output_final > vins_premium.csv > data
1 product_id,product_name,price,total_sales,chiffre_affaires,zscore,premium
2 4115,Zind-Humbrecht Riesling Grand Cru Rangen De Thann Clos Saint-Urbain 2017,100.0,0.0,0.0,2.427385420938595,True
3 4132,Zind-Humbrecht Pinot Gris Grand Cru Rangen De Thann Clos Saint-Urbain 2012,88.4,0.0,0.0,2.0102771487143416,True
4 4352,Champagne Egly-Ouriet Grand Cru Millésimé 2008,225.0,5.0,1125.0,6.922086630251679,True
5 4355,Champagne Egly-Ouriet Grand Cru Blanc de Noirs,126.5,11.0,1391.5,3.380262077312969,True
```

Vins premium

```
data_bottleneck > output_final > vins_ordinaires.csv > data
1 product_id,product_name,price,total_sales,chiffre_affaires,zscore,premium
2 3847,Pierre Jean Villa Saint-Joseph Préface 2018,24.2,6.0,145.2,-0.2982013923888578,False
3 3849,Pierre Jean Villa Saint-Joseph Rouge Tildé 2017,34.3,0.0,0.0,0.06497046532363923,False
4 3850,Pierre Jean Villa Crozes-Hermitage Accroche Coeur 2018,20.8,0.0,0.0,-0.4204572652821736,False
5 4032,Pierre Jean Villa IGP Collines Rhodaniennes Gamine 2018,14.1,3.0,42.3,-0.6613732501013548,False
```

Vins ordinaire

data_bottleneck > output_final >  rapport_chiffre_affaires.xlsx

	A	B
1	indicateur	valeur
2	Nombre de lignes	714
3	Chiffre d'affaires total (€)	65,652.60



Détail_CA

Résumé

SECTION 4 Exports & Orchestration (Output Files)

Export CSV premium

Export CSV ordinary


Export Excel (CA produit + total)

data_bottleneck > output_final > rapport_chiffre_affaires.xlsx					
	A	B	C	D	E
1	product_id	product_name	price	total_sales	chiffre_affaires
2	3,847	Pierre Jean Villa	24.20	6	145.20
3	3,849	Pierre Jean Villa	34.30	0	0
4	3,850	Pierre Jean Villa	20.80	0	0
5	4,032	Pierre Jean Villa	14.10	3	42.30
6	4,039	Pierre Jean Villa	46	0	0
7	4,040	Pierre Jean Villa	34.30	0	0
8	4,041	Pierre Gaillard C	32.70	0	0
9	4,042	Pierre Gaillard C	31.20	7	218.40
10	4,043	Pierre Gaillard C	60	3	180
11	4,045	Pierre Gaillard C	42.60	14	596.40
12	4,046	Pierre Gaillard C	80	6	480
13	4,047	Pierre Gaillard C	18.30	0	0
14	4,048	Pierre Gaillard S	22.80	7	159.60
15	4,049	Pierre Gaillard S	19.30	1	19.30
16	4,050	Pierre Gaillard S	21.80	6	130.80
17	4,051	Jeanne Gaillard I	7.70	6	46.20
18	4,052	Clos du Mont-O	33.70	6	202.20
19	4,053	Clos du Mont-O	44.30	23	1,018.90
20	4,054	Clos du Mont-O	71.60	10	716
21	4,056	Clos du Mont-O	12.70	10	127
22	4,057	Mourgues du Gr	8.70	18	156.60
23	4,058	Mourgues du Gr	8.70	11	95.70
24	4,059	Mourgues du Gr	8.70	7	60.90
25	4,060	Mourgues du Gr	11.90	9	107.10
26	4,062	Mourgues du Gr	11.90	3	35.70
27	4,063	Mourgues du Gr	14.50	3	43.50
28	4,064	Oratoire Saint M	14.40	3	43.20
29	4,065	Oratoire Saint M	19.50	0	0
30	4,066	Oratoire Saint M	20.80	20	416
31	4,067	Gilles Robin Cro	22	19	418

Plan de démo

Ce que je vais vous montrer en live.

1. Lancer une exécution Kestra
2. Topology view
3. Gantt + logs des tests
4. Outputs produits



ROADMAP DE LA MISSION

1. Contexte & objectifs
2. Données sources (Input Files)
3. Architecture d'automatisation/data lineage
4. Différentes étapes du Workflow
5. **Conclusion**

Conclusion

Résumé final + ouverture

Pipeline automatisé, reproductible et testé

Consolidation fiable des ventes multi-systèmes

Livrables exploitables directement par le métier



MERCI